



# Data Pipeline & Data Observability

*AICB-P1 · Garbage in → garbage out — fix thế nào?*

---

**Tên Giảng Viên**

VinUniversity · Phase 1 · 2026

HÃY SUY NGHĨ...

*“Agent của bạn dùng data từ database công ty. Đột nhiên data sai – agent hallucinate. Bạn có biết không?”*

Giữ câu hỏi này trong đầu khi học bài hôm nay

1. Data Pipeline Fundamentals
2. Ingestion – Thu Thập Data Từ Nhiều Nguồn
3. Transform – Làm Sạch & Chuẩn Hóa Data
4. Data Quality – 6 Dimensions
5. Data Observability
6. ETL Automation & Orchestration

- **60–80% thời gian** trong AI project thực tế là data work – không phải model
- Một agent RAG xuất sắc vẫn **hallucinate** nếu vector store được nạp data bẩn
- **Garbage in** → **garbage out**: quality của output tỷ lệ thuận với quality của input data
- Observability = cơ chế phát hiện data sai **trước khi user phàn nàn**

## Thực tế dự án AI:

**20%** – xây model/agent

**80%** – data collection, cleaning, pipeline, monitoring

**Agenda:** Pipeline Fundamentals → Ingestion → Transform for AI → Quality Gates → Observability & Debugging → Orchestration → Lab

# Data Pipeline Fundamentals

---

Hiểu chuỗi xử lý từ nguồn đến agent – ETL, ELT, Batch, Streaming

**Data Pipeline** – Chuỗi các bước tự động hóa việc **thu thập, xử lý, và phân phối** data từ nguồn đến đích

## AI Data Stack điển hình:



**Sources:** DB, API, files, streams

**Pipeline:** ingest + transform

**Storage:** warehouse, vector store

**Serving:** API, cache layer

**Agent:** LLM + tools + RAG

**Scenario:** Agent trả lời câu hỏi về chính sách công ty, ticket hỗ trợ và SOP nội bộ.



- Nếu **ingestion fail**: tài liệu mới không vào store → agent trả lời cũ
- Nếu **transform sai**: chunk xấu, metadata thiếu → retrieve nhầm
- Nếu **index lỗi**: embed thiếu hoặc duplicate → context méo

## Điểm khác với dashboard BI:

BI sai → số sai trên báo cáo

Agent sai → hành động hoặc trả lời sai trực tiếp với user

Vì vậy pipeline cho AI cần thêm:  
**chunking, metadata, embeddings, retrieval checks, trace logs**


## ETL (Extract → Transform → Load)

- Transform **trước** khi load vào kho
- Phù hợp: data nhạy cảm, cần mask trước khi lưu
- Ví dụ: redact PII trong ticket support trước khi embed cho agent
- Tools: Talend, Informatica, custom scripts


## ELT (Extract → Load → Transform)

- Load raw data, transform **sau** trong kho
- Phù hợp: big data, cloud data warehouses
- Ví dụ: load raw docs/logs trước, rồi chunk + enrich trong lakehouse
- Tools: Spark SQL, BigQuery, custom Python jobs





- Dùng khi cần **lọc/ràng buộc trước** khi lưu
- Hợp với data nhạy cảm, dữ liệu production cho agent
- Ví dụ: redact PII rồi mới tạo embeddings



- Dùng khi cần **giữ raw** để replay, backfill, thử nghiệm
- Hợp với RAG/ML có nhiều nguồn và logic transform thay đổi liên tục
- Ví dụ: lưu raw docs trước, sau đó thử nhiều chiến lược chunking

## Chọn ETL nếu

- cần mask PII trước
- schema khá ổn định
- data đi vào agent phải rất sạch
- muốn giảm rủi ro lưu raw nhạy cảm

## Chọn ELT nếu

- nhiều nguồn, nhiều định dạng
- phải backfill / replay thường xuyên
- còn đang thử chunking, labeling, feature engineering
- cần giữ raw cho audit và experiment

## Thực tế

Nhiều team dùng **hybrid**:

Load raw trước, nhưng **ETL các phần nhạy cảm** như PII, secrets, dữ liệu pháp lý trước khi index hoặc serve cho agent.

## Batch Processing

- Xử lý theo lô, theo lịch (hourly/daily)
- **Ưu:** đơn giản, cost thấp, dễ debug
- **Nhược:** latency cao (data trễ vài giờ)
- Dùng khi: training data, daily reports, ETL

## Streaming Processing

- Xử lý realtime khi data xuất hiện
- **Ưu:** latency thấp (ms–giây)
- **Nhược:** phức tạp hơn, cost cao hơn
- Dùng khi: fraud detection, live agent context

# Ingestion – Thu Thập Data Từ Nhiều Nguồn

---

Kết nối nguồn data đa dạng vào pipeline một cách đáng tin cậy

## Structured sources

- **Databases** (PostgreSQL, MySQL): CDC để capture changes
- **Data warehouses**: Snowflake, BigQuery
- **REST / GraphQL APIs**: rate limits cần xử lý

## Unstructured sources

- **Files**: CSV, JSON, Parquet, PDF, Word
- **Object storage**: S3, GCS, Azure Blob
- **Web scraping**: HTML → text extraction

## Event streams

- **Kafka / Kinesis**: high-throughput event bus
- **Webhooks**: push từ external services
- **IoT sensors**: time-series data

**CDC** – Change Data Capture – detect & capture mọi INSERT/UPDATE/DELETE trong database để sync realtime thay vì full scan

## Trong hệ AI/agentic, ingestion thường lấy từ:

- **Knowledge sources:** Notion, Confluence, PDF, Word, SharePoint
- **Transactional data:** CRM, ticketing, order DB, HR systems
- **Logs + feedback:** chat transcripts, tool calls, thumbs up/down, escalation notes

## Thiết kế ingestion tốt cần:

- **Incremental sync:** chỉ lấy phần changed since last run
- **Idempotent upsert:** chạy lại không tạo duplicate chunks
- **Source versioning:** biết bản nào mới nhất, sync lúc nào

**Rate limiting:** source API giới hạn re-q/min → cần exponential backoff

**Backpressure:** consumer xử lý chậm hơn producer → cần buffer hoặc pause signal

**Retry logic:** dead-letter queue cho failed records

**Thực tế AI:** 1 file sync fail có thể khiến policy mới không tới agent

**Câu hỏi user:** “Chính sách hoàn tiền mới nhất là gì?”

Agent cần data từ nhiều nguồn:

- **CRM:** đơn hàng, trạng thái giao dịch
- **Policy docs:** chính sách hoàn tiền theo từng tháng
- **Ticket history:** case tương tự đã được xử lý ra sao
- **Escalation notes:** khi nào agent phải chuyển người thật

Nếu ingestion thiếu **1 nguồn quan trọng**, agent có thể:

- trả lời bằng policy cũ
- không biết ngoại lệ business
- đề xuất hành động không đúng với trạng thái

## Checklist ingestion cho AI:

1. Có lấy **đúng nguồn** không?
2. Có lấy **đủ bản mới nhất** không?
3. Có biết record nào **thất bại** không?
4. Có log được **run ID** và thời gian sync không?

# Transform – Làm Sạch & Chuẩn Hóa Data

---

Biến raw data thành data agent có thể tin tưởng và sử dụng được



- **Missing values:** NULL, empty string, “N/A” – drop, impute, hoặc flag
- **Outliers:** giá trị bất thường ảnh hưởng embedding quality
- **Duplicates:** cùng record xuất hiện nhiều lần → dedup bằng hash hoặc fuzzy match
- **Wrong formats:** date “31/12/2024” vs “2024-12-31” → standardize
- **Encoding issues:** UTF-8 vs Latin-1 → luôn enforce UTF-8

## Text normalization cho AI:

- **Lowercasing:** tùy model, không phải lúc nào cũng cần
- **Unicode normalization:** NFC/NFD cho tiếng Việt
- **Whitespace:** collapse multiple spaces, strip trailing
- **HTML stripping:** loại bỏ tags trước khi embed
- **Language detection:** tách chunks theo ngôn ngữ

**Schema validation:** enforce data contracts – reject records không đúng schema thay vì để lọt vào model

**Ý chính** — BI thường transform để báo cáo; AI transform để model **hiểu đúng ngữ cảnh** và **retrieve đúng evidence**

## Các bước transform thường gặp trong AI:

- **Clean text:** bỏ HTML, ký tự lỗi, OCR noise
- **Chunking:** chia tài liệu thành đoạn vừa ngữ nghĩa, vừa token budget
- **Metadata enrichment:** gắn source, owner, version, effective date
- **Redaction:** loại PII/secrets trước khi embed
- **Canonicalization:** chuẩn hóa tên sản phẩm, mã đơn hàng, timestamp

```
doc = load_pdf("refund-policy.pdf")
text = clean_text(doc.text)
chunks = chunk(text, size=500, overlap=80)

for i, chunk in enumerate(chunks):
    write_record({
        "chunk_id": f"{doc.id}:{i}",
        "content": chunk,
        "source_doc": doc.id,
        "version": doc.updated_at,
        "department": "support"
    })
```

## Chunk quá to:

- chứa nhiều chủ đề → retrieval mơ hồ
- tốn token, giảm chỗ cho reasoning

## Chunk quá nhỏ:

- mất context quan trọng
- câu trả lời thiếu điều kiện hoặc ngoại lệ

## Metadata tốt giúp agent:

- filter theo phòng ban, ngày hiệu lực, loại tài liệu
- hiển thị citation đúng nguồn
- trace ngược về document gốc khi có lỗi

## Chunk tốt thường cần

**content**  
**chunk\_id**  
**source\_doc\_id**  
**section / title**  
**effective\_date**  
**owner / department**  
**version / updated\_at**

**Lưu ý:** Nhiều team chỉ embed “text thuần” mà quên metadata. Kết quả: retrieve được đoạn đúng nhưng không biết nó đến từ bản policy nào.

# Data Quality – 6 Dimensions

---

Đo lường chất lượng data trước khi nó đến tay agent

## 1. Completeness

Không thiếu records hoặc fields quan trọng.  
Check: % NULL, row count so với expected

## 2. Accuracy

Data đúng với thực tế. Check: validate với nguồn gốc, business rules

## 3. Consistency

Cùng entity, cùng format across systems.  
Check: cross-system reconciliation

## 4. Timeliness

Data đủ fresh cho use case. Check: max age, last-updated timestamp

## 5. Validity

Data theo đúng format và domain rules.  
Check: regex patterns, range checks

## 6. Uniqueness

Không có duplicates. Check: dedup rate, composite key uniqueness

**Ý chính** – Trong AI pipeline, data quality không chỉ bảo vệ warehouse mà còn bảo vệ **retrieval**, **tool use** và **final answer**

## Các quality gates nên có:

- **Schema gate:** có đủ content, doc\_id, updated\_at
- **Freshness gate:** policy quá cũ thì reject hoặc cảnh báo
- **Content gate:** text đủ dài, OCR confidence không quá thấp
- **Dedup gate:** cùng chunk không được nạp nhiều lần
- **PII gate:** không embed số thẻ, mật khẩu, access token

```
def validate(record):  
    assert record["content"].strip()  
    assert record["updated_at"] >= cutoff_date  
    assert len(record["content"]) >= 80  
    assert not contains_secret(record["content"])  
    assert record["chunk_id"] not in seen_ids  
  
for record in cleaned_records:  
    validate(record)
```

## Data issue

- Missing documents
- Outdated version
- Duplicate chunks
- Wrong metadata
- Secret leakage

## Agent symptom

- không tìm thấy bằng chứng liên quan
- trả lời dựa trên policy cũ
- lặp lại cùng một ý nhiều lần
- cite sai phòng ban / sai ngày hiệu lực
- làm lộ dữ liệu nhạy cảm cho user

**Điểm dạy học quan trọng:** nhiều lỗi nhìn giống “model hallucination” nhưng gốc rễ thực ra là **data pipeline bug**.

# Data Observability

---

Monitor, alert và debug data problems trước khi agent bị ảnh hưởng

05



**Freshness** – Data có đang được update theo đúng lịch?

**Distribution** – Giá trị phân phối có bất thường không? (null rate, range)

**Volume** – Số lượng records tăng/giảm bất thường?

**Schema** – Cột bị đổi tên, thêm, xóa không?

**Lineage** – Data đến từ đâu, đi qua transform nào?

**Data Lineage** – Track hành trình data từ nguồn gốc → pipeline → chunk/index → retrieved context → model output

**Muốn debug được, phải log ít nhất:**

- question / session ID
- retrieved chunk IDs
- source document version
- embedding/index version
- pipeline run ID

## Scenario: RAG agent trả lời sai

1. User phàn nàn agent đưa thông tin cũ
2. Check **answer trace**: agent đã retrieve chunk nào?
3. Check **Freshness**: chunk đó thuộc policy version ngày nào?
4. Check **Volume**: số documents embed hôm nay có drop về 0 không?
5. Trace **Lineage**: ingestion run 2am fail ở bước sync policy
6. Root cause: API timeout, retry/backoff chưa cấu hình đúng

**Không có observability**: phát hiện sau 8 giờ, 500 users bị ảnh hưởng

## Monitoring metrics cần theo dõi:

- **Pipeline SLA**: % runs hoàn thành đúng giờ
- **Row count delta**:  $\Delta$  records qua các runs
- **Null rate per column**: alert nếu tăng đột biến
- **Schema drift**: tự động detect column changes
- **Data freshness**: max age của records trong store
- **Embedding coverage**: % chunks đã được embed

## Quy trình debug nên đi theo 5 lớp:

1. **Output layer:** agent trả lời gì, cite gì, confidence ra sao?
2. **Retrieval layer:** top-k chunks nào được lấy ra? có zero-hit không?
3. **Index layer:** chunk đó được embed bằng model/version nào?
4. **Pipeline layer:** run nào sinh ra chunk? pass/fail quality gates nào?
5. **Source layer:** tài liệu gốc có đúng, mới và đầy đủ không?

**Lưu ý:** Nếu bạn chỉ nhìn final answer mà không trace được về chunk và source document, bạn đang debug trong bóng tối.

## Fields nên có trong trace log:

- request\_id
- pipeline\_run\_id
- retrieved\_chunk\_ids
- source\_doc\_ids
- source\_version
- embedding\_model
- latency\_ms
- fallback\_used

## Pipeline / data signals

- freshness của knowledge base
- failed sync count, dead-letter queue size
- duplicate chunk rate
- missing metadata rate
- embedding queue lag

## Agent / product signals


- retrieval hit rate
- % answers có citation hợp lệ
- user correction / escalation rate
- tool-call failure rate
- abandoned conversations sau câu trả lời sai

**Quan điểm thực chiến:** observability tốt phải nối được **data issue** → **retrieval issue** → **business impact**.

# ETL Automation & Orchestration

---

Đưa pipeline vào vận hành tự động, đáng tin cậy với error handling đúng chuẩn



## Core concepts:

- **DAG** (Directed Acyclic Graph): định nghĩa thứ tự task
- **Operator**: đơn vị thực thi (PythonOperator, BashOperator, ...)
- **Scheduler**: trigger DAGs theo cron hoặc event
- **Executor**: chạy tasks (Local, Celery, Kubernetes)
- **XCom**: truyền data nhỏ giữa tasks

## Khi nào dùng Airflow:

- Batch pipeline phức tạp với nhiều dependencies
- Team đã có Python skills
- Cần visibility đầy đủ qua UI

## Modern alternatives:

### Prefect

Python-native, ít boilerplate hơn Airflow. Flows = Python functions. Phù hợp team muốn nhanh.

### Dagster

Asset-centric orchestration – model data assets, không phải tasks. Built-in lineage & observability. Phù hợp data-heavy teams.

## Airflow

### **Hay dùng cho:**

batch ETL, retraining theo lịch, multi-step jobs

### **Lý do:**

mature, nhiều operator, UI quen thuộc

## Prefect

### **Hay dùng cho:**

Python pipelines, startup teams, flows cần code nhanh

### **Lý do:**

ít boilerplate, local-to-cloud dễ

## Dagster


### **Hay dùng cho:**

asset-heavy pipelines, lineage rõ, data platform teams

### **Lý do:**

asset model hợp với tables, features, indexes

**Góc nhìn thực tế:** hệ RAG/agent nhỏ thường bắt đầu bằng cron + Python; khi số bước, số nguồn, và số team tăng lên thì mới nâng lên Airflow / Prefect / Dagster.



## Cách dùng trong thực tế:

- **Trigger:** mỗi giờ, khi có file mới, hoặc khi policy đổi
- **Fail fast:** quality gate fail thì **không** cho index tiếp
- **Smoke test:** chạy vài câu hỏi chuẩn để check retrieval
- **Notify:** báo Slack nếu index mới làm hit rate giảm

**Lưu ý:** Trong AI pipeline, orchestration không chỉ “chạy jobs” mà còn kiểm soát **chất lượng đầu vào** trước khi agent dùng data mới.



## Scheduling strategies:

- **Cron-based:** `0 2 * * *` = 2am mỗi ngày – đơn giản, predictable
- **Event-driven:** trigger khi file mới upload hoặc webhook nhận được
- **Dependency-based:** chỉ chạy khi upstream pipeline xong
- **Backfill:** chạy lại pipeline cho historical dates

## Error handling patterns:

- **Retry với backoff:** attempt 1 → 30s → attempt 2 → 2m → ...
- **Dead Letter Queue:** failed records không bị mất, xử lý sau
- **Partial failure:** idempotent tasks để re-run an toàn
- **Alerting:** Slack/email khi pipeline fail
- **SLA breach:** alert khi pipeline trễ so với deadline

**Lưu ý:** Idempotency là bắt buộc: chạy lại pipeline 2 lần phải cho kết quả giống chạy 1 lần. Thiếu idempotency dẫn đến duplicate data trong vector store.

**Mục tiêu:** Build AI data pipeline hoàn chỉnh: thu thập raw docs, làm sạch, chunk, enrich metadata, embed và nạp vào vector store cho agent. Simulate data corruption để đo impact lên retrieval và câu trả lời.

**Deliverable:** (1) Pipeline script: raw → cleaned → chunked → embedded; (2) Quality gates cho schema/freshness/duplicates; (3) Trace log để debug agent answers; (4) So sánh response quality trước/sau fix data

**Thời gian:** 4 giờ (Vibe Coding 1.5h + Lab 2.5h)

## Những ý chính cần nhớ trước khi sang bài tiếp theo

- 1 Data pipeline là **hệ tuần hoàn** của mọi AI product – agent mạnh đến đâu cũng vô dụng nếu data vào bị bẩn
- 2 Pipeline cho AI khác BI ở chỗ phải tối ưu cho **retrieval, context quality, citations** và khả năng debug agent
- 3 Data **quality gates** phải chặn thiếu dữ liệu, dữ liệu cũ, duplicate chunks, metadata sai và secret leakage
- 4 **Observability** tốt cho phép trace từ câu trả lời sai ngược về chunk, pipeline run và source document

## Guardrails & AI Safety

*“Agent hoạt động đúng không có nghĩa là an toàn – cần lớp bảo vệ ở mọi cấp”*

- Đọc: OWASP Top 10 for LLMs ([owasp.org](https://owasp.org))
- Thực hành: Thêm input/output validation vào ETL pipeline từ Lab 10
- Suy nghĩ: Agent của bạn có thể bị poisoned data attack không?

1. **Hidden Technical Debt in Machine Learning Systems** – Sculley et al., Google, NeurIPS 2015. Giải thích tại sao 80% thời gian AI = data work. Kinh điển, đọc trước lớp (30 phút).
2. **Designing Data-Intensive Applications** – Martin Kleppmann. Nền tảng cực tốt để hiểu ingestion, streaming, idempotency, backpressure, và consistency trong hệ thống data.
3. **Designing Machine Learning Systems** – Chip Huyen. Góc nhìn production cho data pipelines, data quality, monitoring và feedback loops trong AI systems.

# Hỏi & Đáp

---

*Garbage in → garbage out. Bạn kiểm soát data quality bằng cách nào trong project của mình?*



# Cảm ơn!

**Ngày tiếp theo:** Guardrails & AI Safety

*labs + source code:* [github.com/vbi-academy/aicb-phase1](https://github.com/vbi-academy/aicb-phase1)