

Day 10

Data Cleaning

Lab Guideline

Created by Vo Tu Duc & Nguyễn Minh Triết
Ha Noi 14.04.026 - @ Vin University

Codelab Roadmap

1. Codelab Overview

- Focus: Data Cleaning Pipeline & PII Sanitization.

2. Tasks & Deliverables

- Focus: Masking, Deduplication, and Validation requirements.

3. Global Checklist

- Focus: GitHub access, Email verification, and Discord connectivity.

4. Environment Setup Guide

- Focus: Forking Repository and GitHub Codespaces configuration.

5. Step-by-step Lab Instructions

- Focus: Coding cleaning.py and local execution.

Tổng quan Codelab (Codelab Overview)

- Bối cảnh: Dữ liệu thô (toxic_sample.json) chưa thể nạp vào AI Agent vì:
 - PII (Riêng tư): Chứa Tên và Email thật của khách hàng (Nguy cơ bảo mật).
 - Zombies (Trùng lặp): Các bản ghi lặp lại làm nhiễu kết quả AI.
 - Outliers (Vô lý): Sản phẩm giá ảo (VD: Bút chì \$99k) hoặc giá âm.
- Mục tiêu: Xây dựng Pipeline làm sạch dữ liệu (Sanitization).



Tasks & Deliverables

- Nhiệm vụ chính: Hoàn thiện script cleaning.py để:
 - a. Masking: Xóa name, ẩn email (VD: v***@gmail.com).
 - b. Deduplicate: Đảm bảo mỗi ID sản phẩm là duy nhất.
 - c. Validate: Loại bỏ giá $> \$5,000$ và giá < 0 .
- Kết quả: Xuất file sanitized_sample.json.
- Câu hỏi thảo luận: Tại sao phải xử lý PII bằng ETL (trước khi lưu trữ) thay vì ELT?



Global Checklist

- Kiểm tra email của mình đã nằm trong danh sách đăng ký của BTC. (Quan trọng vì bạn sẽ phải dùng email này để vào Classroom trong phần Setup Bài Lab)
- Kiểm tra tài khoản GitHub đã liên kết với Email đã đăng ký. (Nếu chưa có tài khoản Github, hãy tạo ngay)
- Đường truyền Internet ổn định để thực hiện Codelab.



Local Checklist

- Trên máy đã cài đặt Git (Mở cmd chạy `git version` để kiểm tra)
- Trên máy đã cài đặt Python < 3.14 (Mở cmd chạy `python --version` để kiểm tra)
- Trên máy đã có IDE Visual Studio Code (VSCode).
- Đã đăng nhập vào GitHub trên VSCode



Hướng dẫn cài đặt Python

(Nếu đã cài Python rồi thì vui lòng bỏ qua phần hướng dẫn này)

Bước 1

- Bấm vào link sau:
<https://www.python.org/downloads/release/python-31010/> (Lưu ý: Chúng ta sẽ cài bản 3.10.10 ổn định)



Bước 2

Files

macOS

[Download macOS 64-bit universal2 installer](#)

Windows

[Download Python install manager](#)

Source release


[Download XZ compressed source tarball](#)

Version	Operating system	Description	File size	Sigstore		GPG	MD5 checksum
Gzipped source tarball	Source release		24.9 MB	.sigstore		SIG	6dbe644dd1a520d9853cf6648084c346
XZ compressed source tarball	Source release		18.7 MB	.sigstore		SIG	7bf85df71bbe7f95e5370b983e6ae684
macOS 64-bit universal2 installer	macOS	for macOS 10.9 and later	39.1 MB	CRT	SIG	SIG	892634724ab799569b512082c8f48c83
Windows installer (64-bit)	Windows	Recommended	27.7 MB	CRT	SIG	SIG	9735797853cba809b13c8396c91354a0
Windows installer (32-bit)	Windows		26.6 MB	CRT	SIG	SIG	a81b81687bc2575c05a30f4b31d6ea00
Windows help file	Windows		9.0 MB	CRT	SIG	SIG	448f8401ade49a7e2156d02512f2f9bf
Windows embeddable package (64-bit)	Windows		8.2 MB	CRT	SIG	SIG	f38a9e7e02a992daa62569b758d0a388
Windows embeddable package (32-bit)	Windows		7.3 MB	CRT	SIG	SIG	a681a7f9b242fe35b4d96d79e15e57d6




Bước 3

Chạy file cài đặt và
chọn như hình




Bước 4

Chọn tất cả các tính
năng như hình rồi bấm
Next



Bước 5

Chọn tất cả các tính năng như hình rồi bấm Install



Bước 6

Sau khi cài đặt, vào cmd
gõ **python --version**

Kết quả hiển thị như
hình là thành công

```
C:\WINDOWS\system32\cmd.exe
Microsoft Windows [Version 10.0.19045.6332]
(c) Microsoft Corporation. All rights reserved.

C:\Users\NguyenMinhTriet>python --version
Python 3.10.10
```



Hướng dẫn hoàn thành bài Lab (1)

Trong VSCode, mở terminal và chạy lệnh sau để tải bài Lab về

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

powershell


PS C:\Users\NguyenMinhTriet\github-classroom\GDGoC-FPTU\data-pipeline-observability-dinhhungng>



git clone <https://github.com/GDGoC-FPTU/day10-cleaning-data>



Tổng quan các Files:



Hướng dẫn hoàn thành bài Lab (2)

Chạy các lệnh sau để kích hoạt môi trường và cài thư viện

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

powershell

PS C:\Users\NguyenMinhTriet\github-classroom\GDGoC-FPTU\data-pipeline-observability-dinhhungng>



```
python -m venv venv  
.\venv\Scripts\activate
```



Hướng dẫn hoàn thành bài Lab (3)


Trong file `cleaning.py`, lần lượt hoàn thành các Tasks

Thay thế toàn bộ code bên dưới để hoàn thành **hàm `mask_email`**

`cleaning.py` X

`cleaning.py` > ...

```
2
3 def mask_email(email):
4     """
5     TODO: Implement this function.
6     Masks the email address by keeping the first character of the username
7     and adding '***' before the domain.
8     Example: vana@gmail.com -> v***@gmail.com
9     """
10    # Your code here
11    pass
12
```



```
def mask_email(email):
    if not email or '@' not in email:
        return email
    parts = email.split('@')
    return parts[0][0] + "***@" + parts[1]
```


Hướng dẫn hoàn thành bài Lab (4)

Thay thế toàn bộ code bên dưới để

hoàn thành **hàm Clean data**

```
cleaning.py
cleaning.py > ...
13 def clean_data(input_file, output_file):
14     # Load the toxic data
15     try:
16         # TODO: Load data from input_file (json)
17         data = []
18     except FileNotFoundError:
19         print(f"Error: {input_file} not found.")
20         return
21     except json.JSONDecodeError:
22         print(f"Error: Failed to decode JSON from {input_file}.")
23         return
24
25     seen_ids = set()
26     sanitized_data = []
27
28     for item in data:
29         # 1. Deduplication: Ensure each id only appears once
30         # TODO: Check if item['id'] is already in seen_ids. If yes, skip it.
31
32         # 2. Outlier Check: Remove any item with price > $5,000
33         # TODO: Get price and check if it's > 5000. If yes, skip it.
34
35         # 3. Sanity Check: Remove any item with price < 0
36         # TODO: Check if price is < 0. If yes, skip it.
37
38         # 4. PII Masking: Remove name and mask email
39
40         # TODO: Remove the 'name' field from the item
41
42         # TODO: Mask the 'email' field using the mask_email function
43
44         # Add to cleaned list and track ID
45         sanitized_data.append(item)
46         # seen_ids.add(...)
47
48     # Save the sanitized data
49     # TODO: Write sanitized_data to output_file with indent=4
```

```
def clean_data(input_file, output_file):
    try:
        with open(input_file, 'r', encoding='utf-8') as f:
            data = json.load(f)
    except FileNotFoundError:
        print(f"Error: {input_file} not found.")
        return
    except json.JSONDecodeError:
        print(f"Error: Failed to decode JSON from {input_file}.")
        return

    seen_ids = set()
    sanitized_data = []

    for item in data:
        item_id = item.get('id')
        if item_id in seen_ids:
            continue
        price = item.get('price')
        if price is not None and price > 5000:
            continue
        if price is not None and price < 0:
            continue
        if 'name' in item:
            del item['name']
```



Hướng dẫn hoàn thành bài Lab (5)

Trong Terminal, gõ lệnh sau để test kết quả

Chạy ETL Pipeline

```
python solution.py
```

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

powershell

PS C:\Users\NguyenMinhTriet\github-classroom\GDGoC-FPTU\data-pipeline-observability-dinhhungng>

python cleaning.py



Hướng dẫn hoàn thành bài Lab (6)

Kết quả sẽ như hình:

```
PS J:\VinUniCodelab\VinUni\Day10-Data-Pipeline-Observability\morning_v2>  
Codelab/VinUni/Day10-Data-Pipeline-Observability/morning_v2/cleaning.py  
Successfully sanitized data. Output saved to sanitized_sample.json  
Original records: 6  
Sanitized records: 3
```

File **sanitized_sample.json** sẽ được tạo ra

Đến bước này thì chúng ta đã hoàn thành bài Lab!



Nộp kết quả bài Lab của bạn

Quét mã QR hoặc điền link:



<https://forms.gle/wGxP6EdvqmLRJYjh9>